

数据科学与工程数学基础

作业提交规范及第 11 次作业

教师：黄定江

助教：陈诺、刘文辉

2023 年 2 月 17 日

作业提交规范

1. 作业提交形式：使用 Word 或 L^AT_EX 编写所得到的电子文档。若使用 Word 编写，将其另存为 PDF 形式，然后提交 PDF 文档。若使用 L^AT_EX 编写，将其编译成 PDF 形式，然后提交 Tex 和 PDF 两个文档。
2. 作业命名规范：提交的电子文档必须命名为：“学号_姓名”。命名示例：50000000000_刘某某。
3. 作业提交途径：点击打开每次作业的传送门网址：[第 11 次作业提交传送门](#)，无需注册和登录，直接上传作业文档即可。注意：传送门将会在截至时间点到达后自动关闭。
4. 作业更改说明：如果需要修改已经提交的作业，只要在截至日期前，再次上传更改后的作业（切记保持同名），即可覆盖已有作业。
5. 作业评分说明：正常提交作业的按照实际评分记录；逾期补交作业的根据逾期情况在实际评分基础上酌情扣分；未交作业的当次作业记为 0 分。

第 11 次作业



提交截至时间：**2023/01/21 周六 12:00 (中午)**

理论部分

习题 1. 写出下述非线性规划的 KKT 条件并求解

$$(1) \quad \text{maximize} \quad f(x) = (x-3)^2$$

$$\text{subject to} \quad 1 \leq x \leq 5$$

$$(2) \quad \text{minimize} \quad f(x) = (x-3)^2$$

$$\text{subject to} \quad 1 \leq x \leq 5$$

解. (1) 原问题等价于

$$\begin{cases} \text{minimize} & -f(x) = (x-3)^2 \\ g_1(x) = -x+1 \leq 5 \\ g_2(x) = x-5 \leq 0 \end{cases}$$

求目标函数和约束函数的梯度得,

$$\nabla_x f(x) = -2(x-3), \nabla_x g_1(x) = -1, \nabla_x g_2(x) = 1$$

将约束引入广义 Lagrange 乘子 v_1, v_2 , 在 KKT 条件上有

$$\begin{cases} -2(x^*-3) - v_1^* + v_2^* = 0 \\ v_1^*(-x^*+1) = 0 \\ v_2^*(x^*-5) = 0 \\ v_1^* \geq 0, v_2^* \geq 0 \end{cases}$$

若 $v_1^* \neq 0, v_2^* \neq 0$, 无解.

若 $v_1^* = 0, v_2^* \neq 0$, 得 $x^* = 5, v_2^* = 4, -f(x^*) = -4$.

若 $v_1^* \neq 0, v_2^* = 0$, 得 $x^* = 1, v_1^* = 4, -f(x^*) = -4$.

若 $v_1^* = 0, v_2^* = 0$, 得 $x^* = 3, f(x^*) = 0$.

因此最优解 $x^* = 1$ 或 $x^* = 5$, $\text{maximize} f(x) = 4$.

(2) 原问题等价于

$$\begin{cases} \text{minimize} & f(x) = (x-3)^2 \\ g_1(x) = -x+1 \leq 5 \\ g_2(x) = x-5 \leq 0 \end{cases}$$

求目标函数和约束函数的梯度得,

$$\nabla_x f(x) = -2(x-3), \nabla_x g_1(x) = -1, \nabla_x g_2(x) = 1$$

将约束引入广义 Lagrange 乘子 v_1, v_2 , 在 KKT 条件上有

$$\begin{cases} 2(x^*-3) - v_1^* + v_2^* = 0 \\ v_1^*(-x^*+1) = 0 \\ v_2^*(x^*-5) = 0 \\ v_1^* \geq 0, v_2^* \geq 0 \end{cases}$$

若 $v_1^* \neq 0, v_2^* \neq 0$, 无解.

若 $v_1^* = 0, v_2^* \neq 0$, 得 $x^* = 5, v_2^* = -4 < 0$, 不是 KKT 点.

若 $v_1^* \neq 0, v_2^* = 0$, 得 $x^* = 1, v_1^* = -4 < 0$, 不是 KKT 点.

若 $v_1^* = 0, v_2^* = 0$, 得 $x^* = 3, f(x^*) = 0$.

因此最优解 $x^* = 3, \minimize f(x) = 0$.

习题 2. 考虑等式约束的最小二乘问题

$$\begin{aligned} & \text{minimize} \quad \|\mathbf{Ax} - \mathbf{b}\|_2^2 \\ & \text{subject to} \quad \mathbf{Gx} = \mathbf{h} \end{aligned}$$

其中 $\mathbf{A} \in \mathbb{R}^{m \times n}, \text{rank}(\mathbf{A}) = n, \mathbf{G} \in \mathbb{R}^{p \times n}, \text{rank}(\mathbf{G}) = p$. 给出 KKT 条件, 推导原问题最优解 x^* 以及对偶问题最优解 v^* 的表达式.

解. 求得 *Lagrangian* 函数为

$$\begin{aligned} L(x, v) &= \|Ax - b\|_2^2 + v^T(Gx - h) \\ &= x^T A^T A x + (G^T v - 2A^T b)^T x - v^T h \end{aligned}$$

可通过如下最优性条件得到函数最小值. 令梯度为 0 得,

$$\nabla_x L(x, v) = 2A^T A x + G^T v - 2A^T b = 0$$

因此当 $x = \frac{1}{2}(A^T A)^{-1}(G^T v - 2A^T b)$ 时, *Lagrangian* 函数取得最小值.

对偶函数为 $g(x) = -\frac{1}{4}(G^T v - 2A^T b)^T (A^T A)^{-1}(G^T v - 2A^T b) - v^T h$.

最优性条件为

$$\begin{cases} 2A^T(Ax^* - b) + G^T v^* = 0 \\ Gx^* = h \end{cases}$$

解方程得,

$$\begin{cases} v^* = 2(G(A^T A)^{-1}G^T)^{-1}(G(A^T A)^{-1}A^T b - h) \\ x^* = (A^T A)^{-1}(A^T b - G^T(G(A^T A)^{-1}G^T)^{-1}(G(A^T A)^{-1}A^T b - h)) \end{cases}$$

习题 3. 用 *Lagrange* 乘子法证明: 矩阵 $\mathbf{A} \in \mathbb{R}^{m \times n}$ 的 2 范数

$$\|\mathbf{A}\|_2 = \max_{\|\mathbf{x}\|_2=1, \mathbf{x} \in \mathbb{R}^n} \|\mathbf{Ax}\|_2$$

的平方是 $\mathbf{A}^T \mathbf{A}$ 的最大特征值。

证明. 优化问题为

$$\begin{aligned} & \text{maximize} \quad f(\mathbf{x}) = \mathbf{x}^T \mathbf{A}^T \mathbf{A} \mathbf{x} \\ & \text{subject to} \quad \mathbf{x}^T \mathbf{x} = 1 \end{aligned}$$

Lagrange 函数为:

$$L(\mathbf{x}) = \mathbf{x}^T \mathbf{A}^T \mathbf{A} \mathbf{x} - \lambda(\mathbf{x}^T \mathbf{x} - 1)$$

$$\frac{\partial L}{\partial \mathbf{x}} = 2\mathbf{A}^T \mathbf{A} \mathbf{x} - 2\lambda \mathbf{x}$$

令 $\frac{\partial L}{\partial \mathbf{x}} = 0$, 有:

$$\mathbf{A}^T \mathbf{A} \mathbf{x} = \lambda$$

这表示在 $f(\mathbf{x})$ 的极大值点, \mathbf{x} 是 $\mathbf{A}^T \mathbf{A}$ 的特征向量, λ 是对应的特征值。此时,

$$f(\mathbf{x}) = \mathbf{x}^T \mathbf{A}^T \mathbf{A} \mathbf{x} = \mathbf{x}^T \lambda \mathbf{x} = \lambda \mathbf{x}^T \mathbf{x} = \lambda$$

因此说明, 为使 $f(\mathbf{x})$ 最大, $f(\mathbf{x}) = \lambda_{\max}(\mathbf{A}^T \mathbf{A})$, 其中 λ_{\max} 表示最大特征值。即

$$\|\mathbf{A}\|_2^2 = \lambda_{\max}(\mathbf{A}^T \mathbf{A})$$

□

习题 4. 用 Lagrange 乘子法求欠定方程 $\mathbf{A}\mathbf{x} = \mathbf{b}$ 的最小二范数解, 其中 $\mathbf{A} \in \mathbb{R}^{m \times n}, m \leq n, \text{rank}(\mathbf{A}) = m$

证明. 优化问题为

$$\text{maximize } f(\mathbf{x}) = \frac{1}{2} \|\mathbf{x}\|_2^2$$

$$\text{subject to } \mathbf{A}\mathbf{x} = \mathbf{b}$$

Lagrange 函数为:

$$L(\mathbf{x}, \boldsymbol{\lambda}) = \frac{1}{2} \mathbf{x}^T \mathbf{x} - \boldsymbol{\lambda}^T (\mathbf{A}\mathbf{x} - \mathbf{b})$$

$$\frac{\partial L}{\partial \mathbf{x}} = \mathbf{x} - \mathbf{A}^T \boldsymbol{\lambda}$$

令 $\frac{\partial L}{\partial \mathbf{x}} = 0$, 有:

$$\mathbf{x} = \mathbf{A}^T \boldsymbol{\lambda}$$

$$g(\boldsymbol{\lambda}) = -\frac{1}{2} \boldsymbol{\lambda}^T \mathbf{A} \mathbf{A}^T \boldsymbol{\lambda} + \boldsymbol{\lambda}^T \mathbf{b}$$

令 $\frac{\partial g}{\partial \boldsymbol{\lambda}} = 0$:

$$-\mathbf{A} \mathbf{A}^T \boldsymbol{\lambda} + \mathbf{b} = 0$$

由 $\mathbf{A} \in \mathbb{R}^{m \times n}, \text{rank}(\mathbf{A}) = m$ 得 $\mathbf{A} \mathbf{A}^T$ 可逆, 因此

$$\boldsymbol{\lambda} = (\mathbf{A} \mathbf{A}^T)^{-1} \mathbf{b}$$

因此, \mathbf{x} 满足 $\mathbf{A}\mathbf{x} = \mathbf{b}$ 的最小二范数解:

$$\mathbf{x} = \mathbf{A}^T (\mathbf{A} \mathbf{A}^T)^{-1} \mathbf{b}$$

□

习题 5. 用最速下降法和精确线搜索计算 $\min f(x) = x_1^2 + x_2^2 + x_3^2$, 初始点 $x^{(0)} = (2, 2, 1)^T$. 当 $(f(x^{(n+1)}) - f(x^{(n)})) < 0.001$ 时迭代终止.

解. 由题意得, $f(x) = x^T x, \nabla_x f(x) = 2x$, 设最速下降法的步长为 λ , 那么

$$\begin{aligned} f(x - \lambda \nabla_x f(x)) &= (x - \lambda \nabla_x f(x))^T (x - \lambda \nabla_x f(x)) \\ &= x^T x - 2\lambda \nabla_x f(x)^T x + \lambda^2 \nabla_x f(x)^T \nabla_x f(x) \end{aligned}$$

在 $x - \lambda \nabla_x f(x)$ 方向上, 使 $f(x)$ 最小的 λ 满足

$$\frac{\partial f(x - \lambda \nabla_x f(x))}{\partial \lambda} = -2\nabla_x f(x)^T x + 2\lambda \nabla_x f(x)^T \nabla_x f(x)$$

得

$$\lambda = \frac{\nabla_x f(x)^T x}{\nabla_x f(x)^T \nabla_x f(x)} = \frac{1}{2}$$

所以,

$$x^{(1)} = x^{(0)} - \frac{1}{2} \nabla_x f(x^{(0)}) = (0, 0, 0)^T$$

$$f(x^{(1)}) = 0$$

$$x^{(2)} = x^{(1)} - \frac{1}{2} \nabla_x f(x^{(1)}) = (0, 0, 0)^T$$

$$f(x^{(2)}) = 0$$

同理可得, $f(x^{(n)}) = 0 (n > 0)$, 因此当 $|f(x^{(n+1)}) - f(x^{(n)})| = 0 < 0.001$ 时, 迭代终止.

习题 6. 使用梯度下降法和固定步长 $\lambda = 0.01$ 计算 $\min f(x) = (x_1 - 1)^2 + 16(x_2 - 2)^2$, 初始点 $x^{(0)} = (2, 3)^T$, 迭代两步后终止.

解. 具体迭代结果:

k	$x^{(k)T}$	g_k^T	f_k	$\ g_k\ _\infty$
0	(2, 3)	(2, 32)	17	32
1	(1.98, 2.68)	[1.96, 21.76]	8.3588	21.76
2	(1.96, 2.46)	[1.9208, 14.7968]	4.3434	14.7968

习题 7. 考虑问题

$$\min f(x) = 3x_1^2 + 3x_2^2 - x_1^2 x_2.$$

从初始点 $x^{(0)} = (1.5, 1.5)^T$ 出发, 用 *Newton* 方法求迭代两步后该问题的解 (可用编写程序辅助计算) .

解. $f(x)$ 的一、二阶导数分别为

$$g(x) = (6x_1 - 2x_1x_2, 6x_2 - x_1^2)^T, \quad G(x) = \begin{bmatrix} 6 - 2x_2 & -2x_1 \\ -2x_1 & 6 \end{bmatrix}$$

$f(x)$ 有三个稳定点: 极小点 $x_{(1)} = (0, 0)^T$, 鞍点 $x_{(2)} = (3\sqrt{2}, 3)^T$ 和 $x_{(3)} = (-3\sqrt{2}, 3)^T$. 在这三个点的 *Hesse* 矩阵分别为

$$G(x_{(1)}) = \begin{bmatrix} 6 & 0 \\ 0 & 6 \end{bmatrix}, \quad G(x_{(2)}) = \begin{bmatrix} 0 & -6\sqrt{2} \\ -6\sqrt{2} & 6 \end{bmatrix}$$

$$G(x_{(3)}) = \begin{bmatrix} 0 & 6\sqrt{2} \\ 6\sqrt{2} & 6 \end{bmatrix}.$$

下面我们从 $x^{(0)} = (1.5, 1.5)^T$, 这时 *Newton* 方法在每一迭代步的信息见下表

k	$x^{(k)^T}$	f_k	$\ g_k\ _\infty$
0	(1.5000, 1.5000)	10.1250	8.1125
1	(-3.7500, -2.2500)	89.0156	48.0633
2	(0.6250, -3.1250)	31.6895	20.6151
3	(0.3190, 0.0014)	0.3052	1.9155
4	(-0.0020, -0.0172)	0.0009	0.1037
5	(-0.0000, -0.0000)	0.0000	0.0000
6	(-0.0000, -0.0000)	0.0000	0.0000

习题 8. 试用 *DFP* 法计算下述二次函数的极小点

$$\min f(x) = 3x_1^2 + x_2^2 - 2x_1x_2 - 4x_1.$$

解. 假设我们从 $\mathbf{x}^{(0)} = (-2, 4)^T$ 开始 (没有规定时, 可以随机选取一个初始点), 并取

$$\bar{\mathbf{H}}^{(0)} = \begin{pmatrix} 1 & 0 \\ 0 & 1 \end{pmatrix}$$

$$\nabla f(\mathbf{x}) = [(6x_1 - 2x_2 - 4), (2x_2 - 2x_1)]^T$$

$$\nabla f(\mathbf{x}^{(0)}) = (-24, 12)^T$$

$$\mathbf{p}^{(0)} = -\bar{\mathbf{H}}^{(0)} \nabla f(\mathbf{x}^{(0)}) = - \begin{pmatrix} 1 & 0 \\ 0 & 1 \end{pmatrix} \begin{pmatrix} -24 \\ 12 \end{pmatrix} = \begin{pmatrix} 24 \\ -12 \end{pmatrix}$$

利用一维搜索, 即 $\min_{\lambda} f(\mathbf{x}^{(0)} + \lambda \mathbf{p}^{(0)})$, 可算得

$$\lambda_0 = \frac{5}{34}$$

$$\mathbf{x}^{(1)} = \mathbf{x}^{(0)} + \lambda_0 \mathbf{p}^{(0)} = \begin{pmatrix} -2 \\ 4 \end{pmatrix} + \frac{5}{34} \begin{pmatrix} 24 \\ -12 \end{pmatrix} = \begin{pmatrix} \frac{26}{17} \\ \frac{38}{17} \end{pmatrix}^T$$

$$\nabla f(\mathbf{x}^{(1)}) = \left(\frac{12}{17}, \frac{24}{17} \right)^T$$

$$\Delta \mathbf{x}^{(0)} = \mathbf{x}^{(1)} - \mathbf{x}^{(0)} = \left(\frac{26}{17}, \frac{38}{17} \right)^T - (-2, 4)^T = \left(\frac{60}{17}, -\frac{30}{17} \right)^T$$

$$\Delta \mathbf{g}^{(0)} = \nabla f(\mathbf{x}^{(1)}) - \nabla f(\mathbf{x}^{(0)}) = \left(\frac{6}{17}, \frac{12}{17} \right)^T - (-12, 6)^T = \left(\frac{210}{17}, -\frac{90}{17} \right)^T$$

$$\begin{aligned} \bar{\mathbf{H}}^{(1)} &= \bar{\mathbf{H}}^{(0)} + \frac{\Delta \mathbf{x}^{(0)} (\Delta \mathbf{x}^{(0)})^T}{(\Delta \mathbf{g}^{(0)})^T \Delta \mathbf{x}^{(0)}} - \frac{\bar{\mathbf{H}}^{(0)} \Delta \mathbf{g}^{(0)} (\Delta \mathbf{g}^{(0)})^T \bar{\mathbf{H}}^{(0)}}{(\Delta \mathbf{g}^{(0)})^T \bar{\mathbf{H}}^{(0)} \Delta \mathbf{g}^{(0)}} \\ &= \begin{pmatrix} 1 & 0 \\ 0 & 1 \end{pmatrix} + \frac{\left(\frac{60}{17}, -\frac{30}{17} \right)^T \left(\frac{60}{17}, -\frac{30}{17} \right)}{\left(\frac{210}{17}, -\frac{90}{17} \right) \left(\frac{60}{17}, -\frac{30}{17} \right)^T} - \frac{\begin{pmatrix} 1 & 0 \\ 0 & 1 \end{pmatrix} \left(\frac{210}{17}, -\frac{90}{17} \right)^T \begin{pmatrix} \frac{210}{17}, -\frac{90}{17} \end{pmatrix} \begin{pmatrix} 1 & 0 \\ 0 & 1 \end{pmatrix}}{\left(\frac{210}{17}, -\frac{90}{17} \right) \begin{pmatrix} 1 & 0 \\ 0 & 1 \end{pmatrix} \left(\frac{210}{17}, -\frac{90}{17} \right)^T} \\ &= \frac{1}{986} \begin{pmatrix} 269 & 299 \\ 299 & 862 \end{pmatrix} \end{aligned}$$

$$\mathbf{p}^{(1)} = -\bar{\mathbf{H}}^{(1)} \nabla f(\mathbf{x}^{(1)}) = -\frac{1}{986} \begin{pmatrix} 269 & 299 \\ 299 & 862 \end{pmatrix} \begin{pmatrix} \frac{12}{17} \\ \frac{24}{17} \end{pmatrix} = -\begin{pmatrix} \frac{18}{29} \\ \frac{42}{29} \end{pmatrix}$$

再由一维搜索 $\min_{\lambda} f(\mathbf{x}^{(1)} + \lambda \mathbf{p}^{(1)})$, 得

$$\lambda_1 = \frac{29}{34}$$

从而

$$\mathbf{x}^{(2)} = \mathbf{x}^{(1)} + \lambda_1 \mathbf{p}^{(1)} = \begin{pmatrix} \frac{26}{17} \\ \frac{38}{17} \end{pmatrix} + \frac{29}{34} \begin{pmatrix} -\frac{18}{29} \\ -\frac{42}{29} \end{pmatrix} = \begin{pmatrix} 1 \\ 1 \end{pmatrix}$$

$$\nabla f(\mathbf{x}^{(2)}) = (0, 0)^T$$

可知 $\mathbf{x}^{(2)} = (1, 1)^T$ 为极小点。

习题 9. 试用二次罚函数法求解如下优化问题:

$$\min f_0(\mathbf{x}) = \frac{1}{3} (x_1 + 1)^3 + x_2$$

$$s.t. f_1(\mathbf{x}) = 1 - x_1 \leq 0$$

$$f_2(\mathbf{x}) = -x_2 \leq 0$$

从初始点 $\mathbf{x}^{(0)} = (2, 0)^T$ 开始, 计算迭代两步后的解。

解. 我们不妨取 $M1 = 1, c = 2$ 。由此，构造无约束优化问题：

$$\min p_1(\mathbf{x}) = \frac{1}{3}(x_1 + 1)^3 + x_2 + [\min(0, x_1 - 1)]^2 + [\min(0, x_2)]^2$$

易求得在 $x^{(0)}$ 处的梯度（严格上是次梯度）为 $((x_1 + 1)^2, 1)^T = (9, 1)$ 。假设这里采用固定步长 $\lambda = 0.1$ ，则 $x^{(1)} = (1.1 - 0.1)^T$ 。这里假定这是该无约束优化问题的最优解，实际上，需要迭代至收敛。

然后，进行第二轮迭代，此时 $M2 = c * M1 = 2$ 。由此，构造无约束优化问题：

$$\min p_1(\mathbf{x}) = \frac{1}{3}(x_1 + 1)^3 + x_2 + 2 * [\min(0, x_1 - 1)]^2 + 2 * [\min(0, x_2)]^2$$

易求得在 $x^{(1)}$ 处的梯度为 $((x_1 + 1)^2, 1 + 4x_2)^T = (4.41, 0.6)$ 。仍假设这里采用固定步长 $\lambda = 0.1$ ，则 $x^{(2)} = (0.659 - 0.16)^T$ 。这样，便求得两次迭代的解。实际上，我们可以注意到罚函数法的解是可能会违背约束条件，通过不断地加大惩罚使得它收敛在可行域内。

习题 10. 试用内点法求解如下优化问题：

$$\begin{aligned} \min f_0(\mathbf{x}) &= \frac{1}{3}(x_1 + 1)^3 + x_2 \\ \text{s.t. } f_1(\mathbf{x}) &= 1 - x_1 \leq 0 \\ f_2(\mathbf{x}) &= -x_2 \leq 0 \end{aligned}$$

解. 参考讲义 *Lec35*，例 3。