

第三章 度量与投影

第 7 讲 正交性与投影

黄定江

DaSE @ ECNU

djhuang@dase.ecnu.edu.cn

- ① 7.1 四个基本子空间
- ② 7.2 四个子空间的正交关系
- ③ 7.3 正交投影
- ④ 7.4 正交基与 Gram-Schmit

1 7.1 四个基本子空间


2 7.2 四个子空间的正交关系

3 7.3 正交投影

4 7.4 正交基与 Gram-Schmit

引入

在数据科学的许多工程应用（如信号降噪滤波、数据降维、主成分分析、时间序列分析）中，许多问题的最优求解都可归结为数据在某个子空间的投影问题。本讲我们讲解投影这一在数据分析中极为重要的数学工具。



7.1.1 四个基本子空间

为了更好的理解子空间与投影，我们先讨论四个基本子空间：

1. 列空间: $\text{Col}(\mathbf{A})$
2. 行空间: $\text{Row}(\mathbf{A}) = \text{Col}(\mathbf{A}^T)$
3. 零空间: $\text{Null}(\mathbf{A})$
4. 左零空间: $\text{Null}(\mathbf{A}^T)$

四个基本子空间也是线性代数中非常重要的概念。

7.1.1 四个基本子空间

约定

为方便叙述, 对于矩阵 $\mathbf{A} \in \mathbb{R}^{m \times n}$, 其 m 个行向量、 n 个列向量分别记作

$$\begin{aligned} \mathbf{r}_1 &= [a_{11}, a_{12}, \dots, a_{1n}]^T \\ \mathbf{r}_2 &= [a_{21}, a_{22}, \dots, a_{2n}]^T \\ &\dots \\ \mathbf{r}_m &= [a_{m1}, a_{m2}, \dots, a_{mn}]^T \end{aligned} \quad \mathbf{a}_1 = \begin{pmatrix} a_{11} \\ a_{21} \\ \vdots \\ a_{m1} \end{pmatrix}, \mathbf{a}_2 = \begin{pmatrix} a_{12} \\ a_{22} \\ \vdots \\ a_{m2} \end{pmatrix}, \dots, \mathbf{a}_n = \begin{pmatrix} a_{1n} \\ a_{2n} \\ \vdots \\ a_{mn} \end{pmatrix}$$

即 $\mathbf{A} = (\mathbf{r}_1, \mathbf{r}_2, \dots, \mathbf{r}_m)^T = (\mathbf{a}_1, \mathbf{a}_2, \dots, \mathbf{a}_n)$

设矩阵 $\mathbf{A} \in \mathbb{R}^{m \times n}$, 则它引出下面四个基本子空间:

定义 1

列空间是其列向量 $\{\mathbf{a}_1, \mathbf{a}_2, \dots, \mathbf{a}_n\}$ 的所有线性组合的集合, 它是 \mathbb{R}^m 的一个子空间, 用符号 $\text{Col}(\mathbf{A})$ 表示, 即有

$$\text{Col}(\mathbf{A}) = \left\{ \mathbf{y} \in \mathbb{R}^m \mid \mathbf{y} = \sum_{j=1}^n \alpha_j \mathbf{a}_j, \alpha_j \in \mathbb{R} \right\} = \text{span}\{\mathbf{a}_1, \mathbf{a}_2, \dots, \mathbf{a}_n\} \quad (1)$$

定义 2

行空间是其行向量 $\{\mathbf{r}_1, \mathbf{r}_2, \dots, \mathbf{r}_m\}$ 的所有线性组合的集合, 它是 \mathbb{R}^n 的一个子空间, 用符号 $\text{Row}(\mathbf{A})$ 表示, 也可以用 $\text{Col}(\mathbf{A}^T)$ 表示, 有

$$\text{Row}(\mathbf{A}) = \text{Col}(\mathbf{A}^T) = \left\{ \mathbf{y} \in \mathbb{R}^n \mid \mathbf{y} = \sum_{i=1}^m \beta_i \mathbf{r}_i, \beta_i \in \mathbb{R} \right\} = \text{span}\{\mathbf{r}_1, \mathbf{r}_2, \dots, \mathbf{r}_m\} \quad (2)$$

定义 3

零空间是所有满足齐次线性方程组 $\mathbf{Ax} = \mathbf{0}$ 的解向量集合，它是 \mathbb{R}^n 的一个子空间，用符号 $\text{Null}(\mathbf{A})$ 表示，即有

$$\text{Null}(\mathbf{A}) = \{\mathbf{x} \in \mathbb{R}^n | \mathbf{Ax} = \mathbf{0}\} \quad (3)$$

定义 4

左零空间是所有满足齐次线性方程组 $\mathbf{A}^T \mathbf{y} = \mathbf{0}$ 的解向量集合，它是 \mathbb{R}^m 的一个子空间，用符号 $\text{Null}(\mathbf{A}^T)$ 表示，即有

$$\text{Null}(\mathbf{A}^T) = \{\mathbf{y} \in \mathbb{R}^m | \mathbf{A}^T \mathbf{y} = \mathbf{0}\} \quad (4)$$

给定一个矩阵，为了获得其四个基本子空间，我们需要用到以下结论：

定理 1

1. 一系列初等行变换不改变矩阵的行空间。
2. 一系列初等行变换不改变矩阵的零空间。
3. 一系列初等列变换不改变矩阵的列空间。
4. 一系列初等列变换不改变矩阵的左零空间。

证明.

[2] 令 E_i 是对应于矩阵 A 的第 i 次初等行变换的初等矩阵。由初等行变换可逆。于是，

$$Bx = (E_k E_{k-1} \cdots E_1 A)x = 0 \Leftrightarrow Ax = 0$$

即齐次线性方程 $Bx = 0$ 与 $Ax = 0$ 具有相同的解向量，从而 A 经过若干次初等行变换后得到的矩阵 B 与 A 具有相同的零空间。 □

例 1

求 3×3 矩阵

$$A = \begin{pmatrix} 1 & 2 & 1 \\ -1 & -1 & 1 \\ 1 & 4 & 5 \end{pmatrix}$$

的行空间、列空间、零空间和左零空间。

解

依次进行初等列变换，得到列简约阶梯型矩阵：

$$\begin{pmatrix} 1 & 2 & 1 \\ -1 & -1 & 1 \\ 1 & 4 & 5 \end{pmatrix} \xrightarrow[C_3 - C_1]{C_2 - 2C_1} \begin{pmatrix} 1 & 0 & 0 \\ -1 & 1 & 2 \\ 1 & 2 & 4 \end{pmatrix} \xrightarrow[C_3 - 2C_2]{C_1 + C_2} \begin{pmatrix} 1 & 0 & 0 \\ 0 & 1 & 0 \\ 3 & 2 & 0 \end{pmatrix}$$

最后的变换结果为:

$$\mathbf{A}_C = \begin{pmatrix} 1 & 0 & 0 \\ 0 & 1 & 0 \\ 3 & 2 & 0 \end{pmatrix}$$

由此得到两个线性无关的列向量 $\mathbf{c}_1 = (1, 0, 3)^T$, $\mathbf{c}_2 = (0, 1, 2)^T$, 它们是列空间 $\text{Col}(\mathbf{A})$ 的基

$$\text{Col}(\mathbf{A}) = \text{span}\{(1, 0, 3)^T, (0, 1, 2)^T\}$$

由于一系列初等列变换不改变左零空间, 根据 \mathbf{A}_C , 知 $-3\mathbf{r}_1 - 2\mathbf{r}_2 + \mathbf{r}_3 = 0$ 。

那么我们就可以根据 \mathbf{A}_C 的主元位置, 矩阵 \mathbf{A} 的主元行是第 1 行和第 2 行, 即行空间 $\text{Col}(\mathbf{A}^T)$ 可以写作

$$\text{Col}(\mathbf{A}^T) = \text{span}\{(1, 2, 1)^T, (-1, -1, 1)^T\}$$

对 \mathbf{A} 进行行初等变换

$$\begin{pmatrix} 1 & 2 & 1 \\ -1 & -1 & 1 \\ 1 & 4 & 5 \end{pmatrix} \xrightarrow[R_2+R_1]{R_3-R_1} \begin{pmatrix} 1 & 2 & 1 \\ 0 & 1 & 2 \\ 0 & 2 & 4 \end{pmatrix} \xrightarrow[R_1-2R_2]{R_3-2R_2} \mathbf{A}_R = \begin{pmatrix} 1 & 0 & -3 \\ 0 & 1 & 2 \\ 0 & 0 & 0 \end{pmatrix}$$

\mathbf{A} 的秩为 2。解方程组 $\mathbf{A}_R \mathbf{x} = \mathbf{0}$ 得到 $\mathbf{x} = k(3, -2, 1)^T$

$$\text{Null}(\mathbf{A}) = \text{span}\{(3, -2, 1)\}^T$$

所以零空间维数为 1。

类似地，我们求解 $\mathbf{A}_C^T \mathbf{x} = \mathbf{0}$ 得到 $\mathbf{x} = k(3, 2, -1)^T$ 所以

$$\text{Null}(\mathbf{A}^T) = \text{span}\{(3, 2, -1)^T\}$$

左零空间的维数也是 1。

7.1.2 四个基本子空间的基

我们接下来的目标是: 求四个基本子空间的基和维数。

线性代数的课程中我们学习过矩阵的行秩等于列秩。因此

定理 2

设 $\mathbf{A} \in \mathbb{R}^{m \times n}$, 则 $\dim(\text{Col}(\mathbf{A})) = \dim(\text{Row}(\mathbf{A})) = \text{rank}(\mathbf{A})$

定理 3

设 $\mathbf{A} \in \mathbb{R}^{m \times n}$ 则

$$\dim(\text{Null}(\mathbf{A})) = n - \text{rank}(\mathbf{A})$$

证明.

我们令 $r = \text{rank}(\mathbf{A})$, 根据定义 $\text{Null}(\mathbf{A}) = \{\mathbf{x} \in \mathbb{R}^n | \mathbf{A}\mathbf{x} = \mathbf{0}\}$ 我们对 \mathbf{A} 做行初等变换和列变换, 将 \mathbf{A} 可以变换为

$$\mathbf{A}' = \begin{pmatrix} \mathbf{I} & \mathbf{B} \\ \mathbf{O} & \mathbf{O} \end{pmatrix} = \begin{pmatrix} 1 & & & b_{11} & b_{12} & \dots & b_{1,n-r} \\ & 1 & & b_{21} & b_{22} & \dots & b_{2,n-r} \\ & & \ddots & \vdots & \vdots & & \vdots \\ & & & 1 & b_{r1} & b_{r2} & \dots & b_{r,n-r} \\ 0 & 0 & 0 & 0 & 0 & 0 & \dots & 0 \\ \vdots & \vdots & \vdots & \vdots & \vdots & \vdots & \dots & \vdots \\ 0 & 0 & 0 & 0 & 0 & 0 & \dots & 0 \end{pmatrix}$$



显然 $\mathbf{A}'\mathbf{x} = \mathbf{0}$ 有以下 $n - r$ 个解

$$\mathbf{x}^{(1)} = \begin{pmatrix} b_{11} \\ \vdots \\ b_{r1} \\ -1 \\ 0 \\ \vdots \\ 0 \end{pmatrix} \quad \mathbf{x}^{(2)} = \begin{pmatrix} b_{12} \\ \vdots \\ b_{r2} \\ 0 \\ -1 \\ \vdots \\ 0 \end{pmatrix} \quad \dots \quad \mathbf{x}^{(n-r)} = \begin{pmatrix} b_{1,n-r} \\ \vdots \\ b_{r,n-r} \\ 0 \\ 0 \\ \vdots \\ -1 \end{pmatrix}$$

并且容易看出向量组 $(\mathbf{x}^{(1)}, \mathbf{x}^{(2)}, \dots, \mathbf{x}^{(n-r)})$ 是一个极大线性无关组。

再注意到, 如果 \mathbf{x} 是方程 $\mathbf{A}'\mathbf{x} = \mathbf{0}$ 的解, 那么当 $x_{r+1}, x_{r+2}, \dots, x_n$ 取定时, 可以唯一确定 \mathbf{x} 。换句话说 $\{\mathbf{x} \in \mathbb{R}^n | \mathbf{A}'\mathbf{x} = \mathbf{0}\}$ 的维数最大为 $n - r$ 。

综上 $\mathbf{A}'\mathbf{x} = \mathbf{0}$ 解空间的维数为 $n - r$, 即 $\mathbf{Ax} = \mathbf{0}$ 解空间的维数为 $n - r$, 即

$$\dim(\text{Null}(\mathbf{A})) = n - r$$

上述的证明过程实际上也就是我们刚刚求解矩阵 \mathbf{A} 零空间 $\text{Null}(\mathbf{A})$ 基底和维数的过程。由此得到秩定理，描述了矩阵的秩与其零空间维数之间的关系。

定理 4

矩阵 $\mathbf{A}_{m \times n}$ 的列空间和行空间的维数相等。这个共同的维数就是矩阵 \mathbf{A} 的秩 $\text{rank}(\mathbf{A})$ ，它与零空间维数之间有下列关系：

$$\dim(\text{Col}(\mathbf{A})) + \dim[\text{Null}(\mathbf{A})] = n \quad (5)$$

利用上述定理我们立刻可以得到以下推论

推论 1

设 $\mathbf{A} \in \mathbb{R}^{m \times n}$ 则

$$\dim(\text{Null}(\mathbf{A}^T)) = m - \text{rank}(\mathbf{A})$$

- ① 7.1 四个基本子空间
- ② 7.2 四个子空间的正交关系
- ③ 7.3 正交投影
- ④ 7.4 正交基与 Gram-Schmit

7.2 四个子空间的正交关系

我们将继续讨论四个基本子空间之间的关系。

设 $\mathbf{A} \in \mathbb{R}^{m \times n}$, \mathbf{A} 的四个基本子空间中, $\text{Col}(\mathbf{A}), \text{Null}(\mathbf{A}^T)$ 都是 \mathbb{R}^m 的子空间, 它们是否有交集? $\text{Col}(\mathbf{A}^T), \text{Null}(\mathbf{A})$ 都是 \mathbb{R}^n 的子空间, 它们是否有交集?

定理 5

设 $\mathbf{A} \in \mathbb{R}^{m \times n}$,

$$\text{Col}(\mathbf{A}) \cap \text{Null}(\mathbf{A}^T) = \{\mathbf{0}\}$$

$$\text{Col}(\mathbf{A}^T) \cap \text{Null}(\mathbf{A}) = \{\mathbf{0}\}$$

证明.

设 $\boldsymbol{v} \in \text{Col}(\boldsymbol{A}^T) \cap \text{Null}(\boldsymbol{A})$, 即 \boldsymbol{v} 在 $\boldsymbol{A} = (\boldsymbol{r}_1, \boldsymbol{r}_2, \dots, \boldsymbol{r}_m)^T$ 的行空间中且 $\boldsymbol{A}\boldsymbol{v} = \mathbf{0}$ 。

设 $\boldsymbol{v} = a_1\boldsymbol{r}_1 + a_2\boldsymbol{r}_2 + \dots + a_m\boldsymbol{r}_m$, 则

$$\boldsymbol{A}\boldsymbol{v} = \mathbf{0} \implies \boldsymbol{r}_1^T \boldsymbol{v} = 0, \dots, \boldsymbol{r}_m^T \boldsymbol{v} = 0 \implies \boldsymbol{v}^T \boldsymbol{v} = 0 \implies \boldsymbol{v} = \mathbf{0}$$

即

$$\text{Col}(\boldsymbol{A}^T) \cap \text{Null}(\boldsymbol{A}) = \{\mathbf{0}\}.$$

同理 $\text{Col}(\boldsymbol{A}) \cap \text{Null}(\boldsymbol{A}^T) = \{\mathbf{0}\}$ 。



定义 5

设 S 和 T 是 \mathbb{R}^n 的两个子空间。如果

$$S \cap T = \{0\}$$

我们称 S 和 T 无交连。

列空间和左零空间是无交连的，行空间和零空间是无交连的。

定义 6

设 S 和 T 是 \mathbb{R}^n 的两个子空间。如果对于 $\forall v \in S, \forall w \in T$ ，均有

$$v^T w = 0$$

我们说 S 垂直于 T ， T 垂直于 S ，记做 $S \perp T, T \perp S$ 。

或者说，子空间 S 和子空间 T 是正交的。

定理 6

正交的两个子空间必定是无交连的。

证明.

假设 \mathbb{R}^n 中的两个子空间 S, T 不是无交连的
则

$$\exists v \neq 0, v \in S \cap T$$

而

$$v^T v \neq 0$$

因而 S 和 T 不正交。从而正交的两个子空间必是无交连的。 □

显然，无交连的子空间不一定是正交的。如 $\text{span}\{(1, 1)^T\}$ 和 $\text{span}\{(1, 0)^T\}$ 。
那么列空间和左零空间，行空间和零空间是正交的么？

例 2

设 \mathbf{A} 是 $m \times n$ 阶阵, 则 $\text{Col}(\mathbf{A})$ 和 $\text{Null}(\mathbf{A}^T)$ 正交, $\text{Col}(\mathbf{A}^T)$ 和 $\text{Null}(\mathbf{A})$ 正交。

证明.

对 $\forall \mathbf{v} \in \text{Null}(\mathbf{A}^T)$, 则

$$\mathbf{v}^T \mathbf{A} = \mathbf{0} \implies \mathbf{v}^T \mathbf{a}_1 = 0, \mathbf{v}^T \mathbf{a}_2 = 0, \dots, \mathbf{v}^T \mathbf{a}_n = 0$$

对 $\forall \mathbf{w} \in \text{Col}(\mathbf{A})$, 有 $\mathbf{w} = \alpha_1 \mathbf{a}_1 + \alpha_2 \mathbf{a}_2 + \dots + \alpha_n \mathbf{a}_n$:

$$\mathbf{v}^T \mathbf{w} = \alpha_1 \mathbf{v}^T \mathbf{a}_1 + \alpha_2 \mathbf{v}^T \mathbf{a}_2 + \dots + \alpha_n \mathbf{v}^T \mathbf{a}_n = 0$$

因此, $\text{Null}(\mathbf{A}^T) \perp \text{Col}(\mathbf{A})$, $\text{Col}(\mathbf{A})$ 和 $\text{Null}(\mathbf{A}^T)$ 正交。

将 \mathbf{A} 换成 \mathbf{A}^T , 我们得到 $\text{Col}(\mathbf{A}^T) \perp \text{Null}(\mathbf{A})$, $\text{Col}(\mathbf{A}^T)$ 和 $\text{Null}(\mathbf{A})$ 正交。 □

相对于正交，正交补是两个子空间更强的一种关系。

定义 7

设 $V \subset \mathbb{R}^n$ 是一个子空间, V 在 \mathbb{R}^n 中的正交补定义为集合

$$\{\boldsymbol{w} \in \mathbb{R}^n \mid \boldsymbol{v}^T \boldsymbol{w} = 0, \forall \boldsymbol{v} \in V\}$$

记作 V^\perp 。

也就是说 V 的正交补空间是 \mathbb{R}^n 中所有和 V 正交的向量构成的集合。

显然一个空间和它的正交补空间是正交的，即 $V \perp V^\perp$ 。

显然 V 与 V^\perp 的和是直和，因此，对于 \mathbb{R}^n 中的任意向量 \boldsymbol{x} 可以唯一的分解成如下形式：

$$\boldsymbol{x} = \boldsymbol{x}_1 + \boldsymbol{x}_2$$

其中 $\boldsymbol{x}_1 \in V, \boldsymbol{x}_2 \in V^\perp$ 并且 $\boldsymbol{x}_1^T \boldsymbol{x}_2 = 0$ 。这种分解形式叫做向量的正交分解。

例 3

证明: $\text{Col}(\mathbf{A}^T)^\perp = \text{Null}(\mathbf{A})$, $\text{Col}(\mathbf{A})^\perp = \text{Null}(\mathbf{A}^T)$ 。

我们已经知道, $\text{Col}(\mathbf{A}^T)$ 和 $\text{Null}(\mathbf{A})$ 是正交的, 也就是说

$$\text{Null}(\mathbf{A}) \subseteq \text{Col}(\mathbf{A}^T)^\perp$$

对 $\forall \mathbf{x} \in \text{Col}(\mathbf{A}^T)^\perp$, \mathbf{x} 和 $\text{Col}(\mathbf{A}^T)$ 中的任意向量正交, 那么:

$$\mathbf{x}^T \mathbf{r}_1 = 0, \mathbf{x}^T \mathbf{r}_2 = 0, \dots, \mathbf{x}^T \mathbf{r}_m = 0$$

即 $\mathbf{A}\mathbf{x} = \mathbf{0}$ 。说明 $\mathbf{x} \in \text{Null}(\mathbf{A})$ 。也即

$$\text{Col}(\mathbf{A}^T)^\perp \subseteq \text{Null}(\mathbf{A})$$

因此 $\text{Col}(\mathbf{A}^T)^\perp = \text{Null}(\mathbf{A})$ 。同样可以证明 $\text{Col}(\mathbf{A})^\perp = \text{Null}(\mathbf{A}^T)$ 。

顾名思义，子空间 \mathbb{V} 在向量空间 \mathbb{R}^n 的正交补空间 \mathbb{V}^\perp 含有正交和补充双重含义：

1. 子空间 \mathbb{V}^\perp 与 \mathbb{V} 正交：
2. 向量空间 \mathbb{R}^n 是子空间 \mathbb{V} 与 \mathbb{V}^\perp 的直和，即 $\mathbb{R}^n = \mathbb{V} \oplus \mathbb{V}^\perp$ 。这表明，向量空间 \mathbb{R}^n 是由子空间 \mathbb{V} 补充 \mathbb{V}^\perp 而成。

正交补空间是一个比正交子空间更严格的概念：当向量空间 \mathbb{R}^n 和子空间 \mathbb{V} 给定之后，和 \mathbb{V} 正交的空间不一定是唯一的，但是 \mathbb{V} 的正交补 \mathbb{V}^\perp 是唯一的。

线性代数基本定理

我们将本节内容总结成线性代数基本定理：

定理 7

(线性代数基本定理) 若 A 是 $m \times n$ 矩阵,

- 1 [正交角度] $Col(A^T) \perp Null(A)$, $Col(A) \perp Null(A^T)$,
- 2 [扩张角度] $Col(A^T) \oplus Null(A) = \mathbb{R}^n$, $Col(A) \oplus Null(A^T) = \mathbb{R}^m$,
- 3 [维数角度] $\dim Col(A^T) + \dim Null(A) = n$, $\dim Col(A) + \dim Null(A^T) = m$ 。

线性代数基本定理

$$\text{Col}(\mathbf{A}^T)^\perp = \text{Null}(\mathbf{A})$$

$$\text{Col}(\mathbf{A})^\perp = \text{Null}(\mathbf{A}^T)$$




图 1: 四个子空间

- 1 7.1 四个基本子空间
- 2 7.2 四个子空间的正交关系
- 3 7.3 正交投影
- 4 7.4 正交基与 Gram-Schmit

7.3.1 引言

- 投影是一类重要的线性变换。
- 投影在图形学，编码理论，统计和机器学习中起着重要作用。
- 在机器学习中，我们经常处理高维数据。高维数据通常很难分析或可视化。
- 但是，高维数据通常具有以下属性：只有少数维包含大多数信息，而其它大多数维对于描述数据的关键属性也不是必需的。当我们压缩或可视化高维数据时，我们将丢失信息。
- 为了最大程度地减少这种压缩损失，我们理想地希望在数据中找到最有用的信息维度。然后，我们可以将原始的高维数据投影到低维特征空间上，并在此低维空间中进行操作，以了解有关数据集的更多信息并提取模式。
- 例如机器学习中主成分分析（PCA）、深度学习中深度自动编码器大量采用了降维的想法。
- 下面，我们将专注于正交投影。

投影

定义 8

设 V 是一向量空间, $U \subseteq V$ 是 V 的一个子空间。如果线性映射 $\pi: V \rightarrow U$ 满足

$$\pi^2 = \pi \circ \pi = \pi$$

则称 π 为投影。

设 π 对应的矩阵 P_π , 显然 P_π 满足 $P_\pi^2 = P_\pi$, 称 P_π 为投影矩阵。

正交投影

本节所讲的投影指正交投影。

正交投影

即给定定义了标准内积和欧氏距离的向量空间 \mathbb{R}^n 中的向量 \mathbf{x} , \mathbb{U} 是 \mathbb{R}^n 的子空间, 求 $\mathbf{y} \in \mathbb{U}$, 使得 $\|\mathbf{y} - \mathbf{x}\|$ 最小, 即

$$\pi_{\mathbb{U}}(\mathbf{x}) = \arg \min_{\mathbf{y} \in \mathbb{U}} \|\mathbf{y} - \mathbf{x}\|,$$


称向量 \mathbf{y} 为向量 \mathbf{x} 在子空间 \mathbb{U} 的正交投影。

因为可以对 \mathbf{x} 正交分解, $\mathbf{x} = \mathbf{x}_1 + \mathbf{x}_2$, 其中 $\mathbf{x}_1 \in \mathbb{U}$, $\mathbf{x}_2 \in \mathbb{U}^\perp$. 所以

$$\|\mathbf{y} - \mathbf{x}\|^2 = \|\mathbf{y} - (\mathbf{x}_1 + \mathbf{x}_2)\|^2 = \|(\mathbf{x}_1 - \mathbf{y}) + \mathbf{x}_2\|^2.$$


而 $\mathbf{x}_1 - \mathbf{y} \in \mathbb{U}$, $\mathbf{x}_2 \in \mathbb{U}^\perp$, 所以 $\|(\mathbf{x}_1 - \mathbf{y}) + \mathbf{x}_2\|^2 = \|\mathbf{x}_1 - \mathbf{y}\|^2 + \|\mathbf{x}_2\|^2$.

所以我们只需令 $\mathbf{y} = \mathbf{x}_1$ 即可, 那么 $\mathbf{x}_2 = \mathbf{x} - \mathbf{y} = \mathbf{x} - \pi_{\mathbb{U}}(\mathbf{x}) \in \mathbb{U}^\perp$.




7.3.2 投影到 1 维子空间

接下来，我们看一下如何寻找一个投影矩阵 \mathbf{P}_π 使得向量投影到某个 1 维子空间上。



(a) Original dataset.



(b) Original data (blue) and their corresponding orthogonal projections (orange) onto a lower-dimensional subspace (straight line).

将 2 维空间的点投影到 1 维子空间上。

7.3.2 投影到 1 维子空间

投影到一维子空间

假设给定 \mathbb{R}^n 中一条通过原点的直线 (1 维子空间), 其具有基向量 \mathbf{b} , 相应的基底矩阵表示为 $\mathbf{B} = [\mathbf{b}]$, 也就是说这组基中仅有一个向量。

这条直线是由 \mathbf{b} 张成的一维子空间 $\mathbb{U} = \text{Col}(\mathbf{B}) \subseteq \mathbb{R}^n$ 。

假设 $\mathbf{x} \in \mathbb{R}^n$, 当把 \mathbf{x} 投影到 \mathbb{U} 时, 我们想寻找一个点 $\pi_{\mathbb{U}}(\mathbf{x}) \in \mathbb{U}$ 最接近 \mathbf{x} , 即

$$\pi_{\mathbb{U}}(\mathbf{x}) = \arg \min_{\mathbf{y} \in \mathbb{U}} \|\mathbf{y} - \mathbf{x}\|$$

因为 $\pi_{\mathbb{U}}(\mathbf{x}) \in \mathbb{U}$, 又 $\mathbb{U} = \text{Col}(\mathbf{B}) = \text{span}\{\mathbf{b}\}$, 所以 $\pi_{\mathbb{U}}(\mathbf{x}) = \lambda \mathbf{b}$, $\lambda \in \mathbb{R}$ 。

我们将结合 $\mathbf{x} - \pi_{\mathbb{U}}(\mathbf{x}) \in \mathbb{U}^\perp$, 逐步确定坐标 λ , 投影 $\pi_{\mathbb{U}}(\mathbf{x}) \in \mathbb{U}$ 和 $\pi_{\mathbb{U}}$ 的投影矩阵 \mathbf{P}_π 。

1. 确定 λ

因为 $\pi_U(\mathbf{x}) \in \text{Col}(\mathbf{B})$ 是 \mathbf{x} 的投影, 所以 $\mathbf{x} - \pi_U(\mathbf{x}) \in \text{Col}(\mathbf{B})^\perp = \text{Null}(\mathbf{B}^\text{T})$, 有

$$\mathbf{b}^\text{T}(\mathbf{x} - \pi_U) = 0 \iff \mathbf{b}^\text{T}\mathbf{x} - \lambda\mathbf{b}^\text{T}\mathbf{b} = 0$$

从而

$$\lambda = \frac{\mathbf{b}^\text{T}\mathbf{x}}{\mathbf{b}^\text{T}\mathbf{b}}$$

或者利用内积和范数表示可得

$$\langle \mathbf{x}, \mathbf{b} \rangle - \lambda \langle \mathbf{b}, \mathbf{b} \rangle = 0 \iff \lambda = \frac{\langle \mathbf{x}, \mathbf{b} \rangle}{\langle \mathbf{b}, \mathbf{b} \rangle} = \frac{\langle \mathbf{x}, \mathbf{b} \rangle}{\|\mathbf{b}\|^2}.$$

7.3.2 投影到 1 维子空间

2. 确定 $\pi_U(\mathbf{x})$


因为 $\pi_U(\mathbf{x}) = \lambda \mathbf{b}$, 由上面的结论可得:

$$\pi_U(\mathbf{x}) = \frac{\langle \mathbf{x}, \mathbf{b} \rangle}{\|\mathbf{b}\|^2} \mathbf{b} = \frac{\mathbf{b}^T \mathbf{x}}{\|\mathbf{b}\|^2} \mathbf{b}$$


我们可以给出 $\pi_U(\mathbf{x})$ 的长度

$$\begin{aligned} \|\pi_U(\mathbf{x})\| &= \|\lambda \mathbf{b}\| = |\lambda| \|\mathbf{b}\| \\ &= |\cos \omega| \|\mathbf{x}\| \|\mathbf{b}\| \frac{\|\mathbf{b}\|}{\|\mathbf{b}\|^2} \\ &= |\cos \omega| \|\mathbf{x}\| \end{aligned}$$

其中 ω 是 \mathbf{x} 和 \mathbf{b} 之间的夹角, $\cos \omega = \frac{\mathbf{b}^T \mathbf{x}}{\|\mathbf{b}\| \|\mathbf{x}\|}$ 。



(a) Projection of $\mathbf{x} \in \mathbb{R}^2$ onto a subspace U with basis vector \mathbf{b} .



(b) Projection of a two-dimensional vector \mathbf{x} with $\|\mathbf{x}\| = 1$ onto a one-dimensional subspace spanned by \mathbf{b} .

7.3.2 投影到 1 维子空间

3. 确定投影矩阵 P_π

投影矩阵 P_π 是投影 $\pi_U(\mathbf{x})$ 对应的变换矩阵, 那么就有 $\pi_U(\mathbf{x}) = P_\pi \mathbf{x}$, 则有

$$\pi_U(\mathbf{x}) = \lambda \mathbf{b} = \mathbf{b} \lambda = \mathbf{b} \frac{\mathbf{b}^T \mathbf{x}}{\|\mathbf{b}\|^2} = \frac{\mathbf{b} \mathbf{b}^T}{\|\mathbf{b}\|^2} \mathbf{x}$$

我们立刻可以看出

$$P_\pi = \frac{\mathbf{b} \mathbf{b}^T}{\|\mathbf{b}\|^2}$$

注:

$\mathbf{b} \mathbf{b}^T$ 是一个对称矩阵, 而 $\mathbf{b}^T \mathbf{b}$ 则是一个标量。

例 4

确定投影到 \mathbb{R}^3 的子空间 $\text{span}\{\mathbf{b}\}$ 上的投影矩阵 \mathbf{P}_π , 其中 $\mathbf{b} = (1, 2, 2)^T$.

由上面的结论可得

$$\mathbf{P}_\pi = \frac{\mathbf{b}\mathbf{b}^T}{\mathbf{b}^T\mathbf{b}} = \frac{1}{9} \begin{pmatrix} 1 \\ 2 \\ 2 \end{pmatrix} \begin{pmatrix} 1 & 2 & 2 \end{pmatrix} = \frac{1}{9} \begin{pmatrix} 1 & 2 & 2 \\ 2 & 4 & 4 \\ 2 & 4 & 4 \end{pmatrix}$$

给定向量 $\mathbf{x} = (1, 1, 1)^T$ 其投影为

$$\pi_{\mathbb{U}}(\mathbf{x}) = \mathbf{P}_\pi(\mathbf{x}) = \frac{1}{9} \begin{pmatrix} 1 & 2 & 2 \\ 2 & 4 & 4 \\ 2 & 4 & 4 \end{pmatrix} \begin{pmatrix} 1 \\ 1 \\ 1 \end{pmatrix} = \frac{1}{9} \begin{pmatrix} 5 \\ 10 \\ 10 \end{pmatrix} \in \text{Col} \left(\begin{pmatrix} 1 \\ 2 \\ 2 \end{pmatrix} \right)$$

7.3.3 投影到一般子空间

我们将 \mathbb{R}^m 中的向量 $\mathbf{x} \in \mathbb{R}^m$ 投影到更高维的子空间 $\mathbb{U} \subseteq \mathbb{R}^m$ 中, 其中 $\dim(\mathbb{U}) = n \geq 1$ 。

投影到一般的子空间中

设 $\mathbf{B} = (\mathbf{b}_1, \dots, \mathbf{b}_n)$ 是子空间 \mathbb{U} 的一个有序基底。 \mathbb{U} 上的任何投影 $\pi_{\mathbb{U}}(\mathbf{x})$ 必须是 \mathbb{U} 中的一个元素。故有

$$\pi_{\mathbb{U}}(\mathbf{x}) = \sum_{i=1}^n \lambda_i \mathbf{b}_i$$

和一维情况一样, 我们将逐步确定 $\lambda_1, \dots, \lambda_n$, $\pi_{\mathbb{U}}(\mathbf{x})$ 和投影矩阵 \mathbf{P}_{π} 。

1. 确定 $\lambda_1, \dots, \lambda_n$

设

$$\pi_{\mathbb{U}}(\mathbf{x}) = \sum_{i=1}^n \lambda_i \mathbf{b}_i = \mathbf{B}\boldsymbol{\lambda} \in \text{Col}(\mathbf{B})$$

最接近 $\mathbf{x} \in \mathbb{R}^m$, 其中 $\mathbf{B} = [\mathbf{b}_1, \dots, \mathbf{b}_n] \in \mathbb{R}^{m \times n}$, $\boldsymbol{\lambda} = [\lambda_1, \dots, \lambda_n]^T \in \mathbb{R}^n$ 。

因为 $\pi_{\mathbb{U}}(\mathbf{x})$ 是 \mathbf{x} 的投影, 所以 $\mathbf{x} - \pi_{\mathbb{U}}(\mathbf{x}) \in \text{Col}(\mathbf{B})^\perp = \text{Null}(\mathbf{B}^T)$

$$\mathbf{b}_1^T(\mathbf{x} - \pi_{\mathbb{U}}(\mathbf{x})) = \langle \mathbf{b}_1, \mathbf{x} - \pi_{\mathbb{U}}(\mathbf{x}) \rangle = 0$$

$$\mathbf{b}_2^T(\mathbf{x} - \pi_{\mathbb{U}}(\mathbf{x})) = \langle \mathbf{b}_2, \mathbf{x} - \pi_{\mathbb{U}}(\mathbf{x}) \rangle = 0$$

$$\vdots$$

$$\mathbf{b}_n^T(\mathbf{x} - \pi_{\mathbb{U}}(\mathbf{x})) = \langle \mathbf{b}_n, \mathbf{x} - \pi_{\mathbb{U}}(\mathbf{x}) \rangle = 0$$

使用矩阵可以将上式改写成

$$b_1^T(x - B\lambda) = 0$$

$$\vdots$$

$$b_n^T(x - B\lambda) = 0$$

故有

$$\begin{pmatrix} b_1^T \\ \vdots \\ b_n^T \end{pmatrix} (x - B\lambda) = 0 \iff B^T(x - B\lambda) = 0 \iff B^T B\lambda = B^T x$$

最终的方程我们称之为正规方程。因为 b_1, \dots, b_n 是 \mathbb{U} 的基。因此 $B^T B$ 是可逆的 ($B^T B y = 0 \implies y^T B^T B y = 0 \implies B y = 0$)。也就是说

$$\lambda = (B^T B)^{-1} B^T x$$

2. 确定 $\pi_{\mathbb{U}}(\boldsymbol{x})$

$$\boldsymbol{\lambda} = (\boldsymbol{B}^T \boldsymbol{B})^{-1} \boldsymbol{B}^T \boldsymbol{x}$$

$\boldsymbol{\lambda}$ 也就是 $\pi_{\mathbb{U}}(\boldsymbol{x})$ 在有序基底 \boldsymbol{B} 下的坐标。

$$\pi_{\mathbb{U}}(\boldsymbol{x}) = \boldsymbol{B}\boldsymbol{\lambda} = \boldsymbol{B}(\boldsymbol{B}^T \boldsymbol{B})^{-1} \boldsymbol{B}^T \boldsymbol{x}$$

3. 确定 \boldsymbol{P}_{π}

由上面的讨论容易看出

$$\boldsymbol{P}_{\pi} = \boldsymbol{B}(\boldsymbol{B}^T \boldsymbol{B})^{-1} \boldsymbol{B}^T$$

例 5

已知 \mathbb{R}^3 中的子空间 $\mathbb{U} = \text{span} \left\{ \begin{pmatrix} 1 \\ 1 \\ 1 \end{pmatrix}, \begin{pmatrix} 0 \\ 1 \\ 2 \end{pmatrix} \right\}$ 和向量 $\mathbf{x} = \begin{pmatrix} 6 \\ 0 \\ 0 \end{pmatrix}$,

确定 \mathbf{x} 投影到 \mathbb{U} 上的坐标 $\boldsymbol{\lambda}$ 和投影点 $\pi_{\mathbb{U}}(\mathbf{x})$ 和投影矩阵 \mathbf{P}_{π}

解

首先确定 $\mathbf{B} = \begin{pmatrix} 1 & 0 \\ 1 & 1 \\ 1 & 2 \end{pmatrix}$

其次计算

$$\mathbf{B}^T \mathbf{B} = \begin{pmatrix} 1 & 1 & 1 \\ 0 & 1 & 2 \end{pmatrix} \begin{pmatrix} 1 & 0 \\ 1 & 1 \\ 1 & 2 \end{pmatrix} = \begin{pmatrix} 3 & 3 \\ 3 & 5 \end{pmatrix}, \quad \mathbf{B}^T \mathbf{x} = \begin{pmatrix} 1 & 1 & 1 \\ 0 & 1 & 2 \end{pmatrix} \begin{pmatrix} 6 \\ 0 \\ 0 \end{pmatrix} = \begin{pmatrix} 6 \\ 0 \end{pmatrix}$$

然后只需要解方程 $B^T B \lambda = B^T x$ 得到 λ ,

$$\begin{pmatrix} 3 & 3 \\ 3 & 5 \end{pmatrix} \begin{pmatrix} \lambda_1 \\ \lambda_2 \end{pmatrix} = \begin{pmatrix} 6 \\ 0 \end{pmatrix} \iff \lambda = \begin{pmatrix} 5 \\ -3 \end{pmatrix}$$

故投影点 $\pi_U(x) = B\lambda = \begin{pmatrix} 5 \\ 2 \\ -1 \end{pmatrix}$ 。最后

$$P_\pi = B(B^T B)^{-1} B^T = \frac{1}{6} \begin{pmatrix} 5 & 2 & -1 \\ 2 & 2 & 2 \\ -1 & 2 & 5 \end{pmatrix}$$


我们还可以验证 $P_\pi^2 = P_\pi$

- 投影使我们可以研究线性系统 $Ax = b$ 没有解的情况。
- 回想一下，方程无解意味着 b 不在 A 的范围内，即向量 b 不在 A 的列张成的子空间中。
- 鉴于线性方程无法精确求解，我们可以找到一个近似解。
- 想法是在 A 的列张成的子空间中找到最接近 b 的向量，即，我们计算 b 到 A 列张成的子空间上的正交投影。
- 此问题在实践中经常出现，并且解被称为超定系统的最小二乘解。


7.3.4 投影到仿射子空间

到目前为止，我们讨论了如何将向量投影到低维子空间 U 上。


下面，我们将讨论如何将向量投影到仿射子空间上。



(a) Setting.



(b) Reduce problem to projection π_U onto vector subspace.



(c) Add support point back in to get affine projection π_L .

图 2: 投影到仿射空间


考虑图 (a)。给定一个仿射空间 $\mathbb{L} = \mathbf{x}_0 + \mathbb{U}$ ，其中 $\mathbf{b}_1, \mathbf{b}_2$ 是 \mathbb{U} 的基向量。为了确定 \mathbf{x} 在 \mathbb{L} 上的正交投影 $\pi_{\mathbb{L}}(\mathbf{x})$ 。

我们将问题转化为我们知道如何解决的问题：投影到向量子空间上。为此，我们从 \mathbf{x} 和 \mathbb{L} 中减去支撑点 \mathbf{x}_0 ，所以 $\mathbb{L} - \mathbf{x}_0 = \mathbb{U}$ 恰好是向量子空间 \mathbb{U} 。


现在，我们可以用前面讨论过的在子空间上的正交投影，来获得投影 $\pi_{\mathbb{U}}(\mathbf{x} - \mathbf{x}_0)$ ，如图 (b) 所示。

最后我们通过添加 \mathbf{x}_0 将该投影转换回 \mathbb{L} ，这样我们就可以得出仿射空间 \mathbb{L} 上的正交投影为


$$\pi_{\mathbb{L}}(\mathbf{x}) = \mathbf{x}_0 + \pi_{\mathbb{U}}(\mathbf{x} - \mathbf{x}_0)$$



(a) Setting.



(b) Reduce problem to projection $\pi_{\mathbb{U}}$ onto vector subspace.



(c) Add support point back in to get affine projection $\pi_{\mathbb{L}}$.

- ① 7.1 四个基本子空间
- ② 7.2 四个子空间的正交关系
- ③ 7.3 正交投影
- ④ 7.4 正交基与 Gram-Schmit

7.4.1 标准正交基

线性代数中已经学过，线性空间中的向量可以由该空间的一组基表示。

[回忆：标准正交基]

设 n 维向量 $\mathbf{e}_1, \mathbf{e}_2, \dots, \mathbf{e}_r$ 是向量空间 $\mathbb{V} (\mathbb{V} \subset \mathbb{R}^n)$ 的一个基，如果 $\mathbf{e}_1, \dots, \mathbf{e}_r$ 两两正交，且都是单位向量，即对于 $\forall i, j = 1, \dots, r$ ，有

$$\langle \mathbf{e}_i, \mathbf{e}_j \rangle = \begin{cases} 0, i \neq j \\ 1, i = j \end{cases}$$

则称 $\mathbf{e}_1, \dots, \mathbf{e}_r$ 是 \mathbb{V} 的一个规范 (标准) 正交基，有时也简称做正交基。

为什么需要标准正交基的概念？用标准正交基表示向量有什么好处呢？

7.4.1 标准正交基

若 $\mathbf{e}_1, \dots, \mathbf{e}_r$ 是 \mathbb{V} 的一个规范正交基, 那么 \mathbb{V} 中任意向量 \mathbf{a} 可以由 $\mathbf{e}_1, \dots, \mathbf{e}_r$ 线性表示, 设表示为

$$\mathbf{a} = \lambda_1 \mathbf{e}_1 + \lambda_2 \mathbf{e}_2 + \dots + \lambda_r \mathbf{e}_r,$$

为求其中的系数 $\lambda_i (i = 1, \dots, r)$, 可以计算 \mathbf{e}_i 与 \mathbf{a} 的内积, 有

$$\langle \mathbf{e}_i, \mathbf{a} \rangle = \langle \mathbf{e}_i, \lambda_1 \mathbf{e}_1 + \lambda_2 \mathbf{e}_2 + \dots + \lambda_r \mathbf{e}_r \rangle = \lambda_1 \langle \mathbf{e}_i, \mathbf{e}_1 \rangle + \lambda_2 \langle \mathbf{e}_i, \mathbf{e}_2 \rangle + \dots + \lambda_r \langle \mathbf{e}_i, \mathbf{e}_r \rangle = \lambda_i$$

即

$$\lambda_i = \langle \mathbf{a}, \mathbf{e}_i \rangle$$

利用这个公式能方便地求得向量的坐标。

因此, 我们给向量空间取基时常常取标准正交基。

接下来我们应用投影的思想, 确定 $\text{Col}(\mathbf{A})$ 中的一组标准正交基。

投影与基的正交化

设 $\mathbf{a}_1, \dots, \mathbf{a}_r$ 是向量空间 \mathbb{V} 的一个基：我们的目的是找到一组正交基 $\mathbf{e}_1, \dots, \mathbf{e}_r$ 使得

$$\text{span}\{\mathbf{e}_1, \dots, \mathbf{e}_r\} = \text{span}\{\mathbf{a}_1, \dots, \mathbf{a}_r\}$$

我们可以这样做，我们先取 \mathbf{a}_1 作为一个基，记为 \mathbf{b}_1 。那么 \mathbf{a}_2 可以正交分解

$$\mathbf{a}_2 = \mathbf{a}_2^{(1)} + \mathbf{a}_2^{(2)},$$

其中 $\mathbf{a}_2^{(1)} \in \text{Col}((\mathbf{a}_1))$, $\mathbf{a}_2^{(2)} \in \text{Null}((\mathbf{a}_1)^T)$ 。利用投影公式：

$$\mathbf{a}_2^{(1)} = \frac{\langle \mathbf{b}_1, \mathbf{a}_2 \rangle}{\langle \mathbf{b}_1, \mathbf{b}_1 \rangle} \mathbf{b}_1$$

$$\mathbf{a}_2^{(2)} = \mathbf{a}_2 - \frac{\langle \mathbf{b}_1, \mathbf{a}_2 \rangle}{\langle \mathbf{b}_1, \mathbf{b}_1 \rangle} \mathbf{b}_1$$

我们记 $\mathbf{a}_2^{(2)}$ 为 \mathbf{b}_2 。并把 \mathbf{b}_2 添加到正交基中， $\text{span}\{\mathbf{a}_1, \mathbf{a}_2\} = \text{span}\{\mathbf{b}_1, \mathbf{b}_2\}$ 。注意这里 $\mathbf{b}_1, \mathbf{b}_2$ 还不是标准正交基。

假设我们已经有了 一组有序正交基底 $B_k = (b_1, b_2, \dots, b_k)$, 那么 a_{k+1} 可以正交分解

$$a_{k+1} = a_{k+1}^{(1)} + a_{k+1}^{(2)},$$

其中 $a_{k+1}^{(1)} \in \text{Col}(B_k)$, $a_{k+1}^{(2)} \in \text{Null}(B_k^T)$ 。利用投影公式:

$$\begin{aligned} a_{k+1}^{(1)} &= \pi_{\text{Col}(B_k)}(a_{k+1}) = B_k(B_k^T B_k)^{-1} B_k^T a_{k+1} \\ &= (b_1, \dots, b_k) \begin{pmatrix} \langle b_1, b_1 \rangle & \cdots & \langle b_1, b_k \rangle \\ \vdots & \ddots & \vdots \\ \langle b_k, b_1 \rangle & \cdots & \langle b_k, b_k \rangle \end{pmatrix}^{-1} \begin{pmatrix} \langle b_1, a_{k+1} \rangle \\ \vdots \\ \langle b_k, a_{k+1} \rangle \end{pmatrix} \end{aligned}$$

而 $\{b_1, \dots, b_k\}$ 是相互正交的。也就是说若 $i \neq j$, $\langle b_i, b_j \rangle = 0$ 。

所以

$$\begin{aligned} \mathbf{a}_{k+1}^{(1)} &= (\mathbf{b}_1, \dots, \mathbf{b}_k) \begin{pmatrix} \langle \mathbf{b}_1, \mathbf{b}_1 \rangle & & \\ & \ddots & \\ & & \langle \mathbf{b}_k, \mathbf{b}_k \rangle \end{pmatrix}^{-1} \begin{pmatrix} \langle \mathbf{b}_1, \mathbf{a}_{k+1} \rangle \\ \vdots \\ \langle \mathbf{b}_k, \mathbf{a}_{k+1} \rangle \end{pmatrix} \\ &= \frac{\langle \mathbf{b}_1, \mathbf{a}_{k+1} \rangle}{\langle \mathbf{b}_1, \mathbf{b}_1 \rangle} \mathbf{b}_1 + \frac{\langle \mathbf{b}_2, \mathbf{a}_{k+1} \rangle}{\langle \mathbf{b}_2, \mathbf{b}_2 \rangle} \mathbf{b}_2 + \dots + \frac{\langle \mathbf{b}_k, \mathbf{a}_{k+1} \rangle}{\langle \mathbf{b}_k, \mathbf{b}_k \rangle} \mathbf{b}_k \end{aligned}$$

而 $\mathbf{a}_{k+1}^{(2)} = \mathbf{a}_{k+1} - \mathbf{a}_{k+1}^{(1)}$, 我们记 $\mathbf{a}_{k+1}^{(2)}$ 为 \mathbf{b}_{k+1} , 并把 \mathbf{b}_{k+1} 添加到正交基中, $\text{span}\{\mathbf{a}_1, \mathbf{a}_2, \dots, \mathbf{a}_{k+1}\} = \text{span}\{\mathbf{b}_1, \mathbf{b}_2, \dots, \mathbf{b}_{k+1}\}$ 。

以此类推, 我们可以得到 $\{\mathbf{b}_1, \mathbf{b}_2, \dots, \mathbf{b}_r\}$ 使得

$$\text{span}\{\mathbf{a}_1, \mathbf{a}_2, \dots, \mathbf{a}_r\} = \text{span}\{\mathbf{b}_1, \mathbf{b}_2, \dots, \mathbf{b}_r\}.$$

只需要再把这组基单位化即可。

7.4.2 Gram-Schmidt 正交化

总结之前的过程，可以通过以下方法求得 \mathbb{V} 的一个规范正交基 e_1, \dots, e_r 。

这种方法称为 Gram-Schmidt 正交化。

取

$$b_1 = a_1;$$

$$b_2 = a_2 - \frac{\langle b_1, a_2 \rangle}{\langle b_1, b_1 \rangle} b_1;$$

.....

$$b_r = a_r - \frac{\langle b_1, a_r \rangle}{\langle b_1, b_1 \rangle} b_1 - \frac{\langle b_2, a_r \rangle}{\langle b_2, b_2 \rangle} b_2 - \dots - \frac{\langle b_{r-1}, a_r \rangle}{\langle b_{r-1}, b_{r-1} \rangle} b_{r-1}$$

然后把它们单位化，取

$$e_1 = \frac{1}{\|b_1\|} b_1, e_2 = \frac{1}{\|b_2\|} b_2, \dots, e_r = \frac{1}{\|b_r\|} b_r$$

就是 \mathbb{V} 的一个规范正交基。

例 6

求向量组 $\mathbf{a}_1 = (3, 1, 1)^T$, $\mathbf{a}_2 = (2, 2, 0)^T$ 的生成子空间的标准正交基。

取

$$\mathbf{b}_1 = (3, 1, 1)^T$$

$$\mathbf{b}_2 = \mathbf{a}_2 - \frac{\mathbf{b}_1^T \mathbf{a}_2}{\mathbf{b}_1^T \mathbf{b}_1} \mathbf{b}_1 = (2, 2, 0)^T - \frac{8}{11} (3, 1, 1)^T = \frac{-2}{11} (1, -7, 4)^T$$

$$\mathbf{e}_1 = \frac{1}{\sqrt{11}} (3, 1, 1)^T$$

$$\mathbf{e}_2 = \frac{1}{\sqrt{66}} (1, -7, 4)^T$$

故标准正交基为 $\mathbf{e}_1, \mathbf{e}_2$: 即,

$$\frac{1}{\sqrt{11}} (3, 1, 1)^T, \frac{1}{\sqrt{66}} (1, -7, 4)^T$$

本讲小结

四个基本子空间

- 行空间
- 列空间
- 零空间
- 左零空间
- 正交关系

正交投影

- 1 维子空间
- 一般子空间
- 仿射子空间
- 正交基与 Gram-Schmit

正交和投影是基础性概念，与超定系统的最小二乘解，并与机器学习中的降维、分类或回归都有紧密联系，我们在后续章节中进一步给出。