

第十章 优化基础

第 31 讲 凸优化问题

黄定江

DaSE @ ECNU

djhuang@dase.ecnu.edu.cn

1 31.1 凸优化概念和性质

2 31.2 典型凸优化问题

1 31.1 凸优化概念和性质

2 31.2 典型凸优化问题

31.1.1 凸优化问题

标准形式的凸优化问题

$$\begin{aligned} \min \quad & f_0(\mathbf{x}) \\ \text{s.t.} \quad & f_i(\mathbf{x}) \leq 0, \quad i = 1, \dots, m \\ & \mathbf{a}_j^T \mathbf{x} = b_j, \quad j = 1, \dots, p \end{aligned}$$

- f_0, \dots, f_m 为凸函数；等式约束是仿射的。

凸优化问题

标准形式的凸优化问题也经常等价地表达为：

$$\begin{aligned} \min \quad & f_0(\mathbf{x}) \\ \text{s.t.} \quad & f_i(\mathbf{x}) \leq 0, \quad i = 1, \dots, m \\ & \mathbf{Ax} = \mathbf{b} \end{aligned}$$

有时原凸优化问题并非上述形式，但可以进行转化成标准形式。如下例题：

例 1

$$\begin{aligned} \min \quad & f_0(\mathbf{x}) = x_1^2 + x_2^2 \\ \text{s.t.} \quad & f_1(\mathbf{x}) = x_1/(1 + x_2^2) \leq 0 \\ & h_1(\mathbf{x}) = (x_1 + x_2)^2 = 0 \end{aligned}$$

可转化成：

$$\begin{aligned} \min \quad & f_0(\mathbf{x}) = x_1^2 + x_2^2 \\ \text{s.t.} \quad & f_1(\mathbf{x}) = x_1 \leq 0 \\ & h_1(\mathbf{x}) = x_1 + x_2 = 0 \end{aligned}$$

31.1.2 凸问题的其他等价转换

如果从一个问题的解，容易得到另一个问题的解，且反之亦然，称两问题 (非正式定义)等价。

- 消除等式约束

$$\begin{aligned} \min \quad & f_0(\mathbf{x}) \\ \text{s.t.} \quad & f_i(\mathbf{x}) \leq 0, \quad i = 1, \dots, m \\ & \mathbf{Ax} = \mathbf{b} \end{aligned}$$

等价于

$$\begin{aligned} \min \quad & f_0(\mathbf{Fz} + \mathbf{x}_0) \\ \text{s.t.} \quad & f_i(\mathbf{Fz} + \mathbf{x}_0) \leq 0, \end{aligned}$$

其中 \mathbf{F} 和 \mathbf{x}_0 满足：

$$\mathbf{Ax} = \mathbf{b} \iff \mathbf{x} = \mathbf{Fz} + \mathbf{x}_0$$

- 引入等式约束

$$\begin{array}{ll}\min & f_0(\mathbf{A}_0\mathbf{x} + \mathbf{b}_0) \\ \text{s.t.} & f_i(\mathbf{A}_i\mathbf{x} + \mathbf{b}_i) \leq 0, \quad i = 1, \dots, m\end{array}$$

等价于

$$\begin{array}{ll}\min & f_0(\mathbf{y}_0) \\ \text{s.t.} & f_i(\mathbf{y}_i) \leq 0, \quad i = 1, \dots, m \\ & \mathbf{y}_i = \mathbf{A}_i\mathbf{x} + \mathbf{b}_i, \quad i = 0, \dots, m\end{array}$$

- 引入松弛变量

$$\begin{array}{ll}\min & f_0(\mathbf{x}) \\ \text{s.t.} & \mathbf{a}_i^T \mathbf{x} \leq b_i, \quad i = 1, \dots, m\end{array}$$

等价于

$$\begin{array}{ll}\min & f_0(\mathbf{x}) \\ \text{s.t.} & \mathbf{a}_i^T \mathbf{x} + s_i = b_i, \quad i = 1, \dots, m \\ & s_i \geq 0, \quad i = 1, \dots, m\end{array}$$

- 转化为上镜图形式

$$\begin{array}{ll}\min & f_0(\mathbf{x}) \\ \text{s.t.} & f_i(\mathbf{x}) \leq 0, \quad i = 1, \dots, m \\ & \mathbf{Ax} = \mathbf{b}\end{array}$$

等价于

$$\begin{array}{ll}\min & t \\ \text{s.t.} & f_0(\mathbf{x}) - t \leq 0 \\ & f_i(\mathbf{x}) \leq 0, \quad i = 1, \dots, m \\ & \mathbf{Ax} = \mathbf{b}\end{array}$$

目标函数是线性的 (因而也是凸的) 并且新的约束函数 $f_0(\mathbf{x}) - t$ 也是 (\mathbf{x}, t) 上的凸函数, 所以上境图问题也是凸的。

- 转化为极小化部分变量的优化问题

极小化凸函数的部分变量将保持凸性不变。因此，对于问题

$$\begin{array}{ll}\min & f_0(\mathbf{x}_1, \mathbf{x}_2) \\ \text{s.t.} & f_i(\mathbf{x}_1) \leq 0, \quad i = 1, \dots, m_1 \\ & \tilde{f}_i(\mathbf{x}_2) \leq 0, \quad i = 1, \dots, m_2,\end{array}$$

这里假定变量 $\mathbf{x} \in \mathbf{R}^n$ 被分为 $\mathbf{x} = (\mathbf{x}_1, \mathbf{x}_2)$, 其中 $\mathbf{x}_1 \in \mathbf{R}^{n_1}$, $\mathbf{x}_2 \in \mathbf{R}^{n_2}$, 并且 $n_1 + n_2 = n$ 。我们首先优化 \mathbf{x}_2 : 定义 \mathbf{x}_1 的函数 \tilde{f}_0 为

$$\tilde{f}_0(\mathbf{x}_1) = \inf \left\{ f_0(\mathbf{x}_1, \mathbf{z}) \mid \tilde{f}_i(\mathbf{z}) \leq 0, i = 1, \dots, m_2 \right\}.$$

则原问题等价于

$$\begin{array}{ll}\min & \tilde{f}_0(\mathbf{x}_1) \\ \text{s.t.} & f_i(\mathbf{x}_1) \leq 0, \quad i = 1, \dots, m_1\end{array}$$

31.1.3 凸优化的全局最优性

定理 1

凸优化问题中，局部最优点就是 (全局) 最优点。

Proof.

设 \mathbf{x} 是凸优化问题的局部最优解，即存在 $R > 0$ ，对任意可行的 \mathbf{z} 且 $\|\mathbf{z} - \mathbf{x}\|_2 \leq R$ ，则 $f_0(\mathbf{z}) \geq f_0(\mathbf{x})$ 。设 \mathbf{y} 是最优点使得 $f_0(\mathbf{y}) < f_0(\mathbf{x})$ 。

考虑 $\mathbf{z} = (1 - \theta)\mathbf{x} + \theta\mathbf{y}$ ，其中 $\theta = R/2\|\mathbf{y} - \mathbf{x}\|_2$

- $\|\mathbf{y} - \mathbf{x}\|_2 > R$ ，因此 $0 < \theta < 1/2$
- \mathbf{z} 是两个可行点的凸组合，因此也是可行的
- $\|\mathbf{z} - \mathbf{x}\|_2 = R/2 < R$ 又 $f_0(\mathbf{z}) \leq (1 - \theta)f_0(\mathbf{x}) + \theta f_0(\mathbf{y}) < f_0(\mathbf{x})$ 。这与 \mathbf{x} 是局部最优解矛盾。

1 31.1 凸优化概念和性质

2 31.2 典型凸优化问题

31.2.1 线性规划 (LP)

$$\begin{array}{ll}\min & \mathbf{c}^T \mathbf{x} + d \\ \text{s.t.} & \mathbf{G}\mathbf{x} \leq \mathbf{h} \\ & \mathbf{A}\mathbf{x} = \mathbf{b}\end{array}$$

- 目标函数和约束函数都是仿射的凸优化问题
- 可行集是一个多面体

例 2

分片线性极小化

$$\min_{\mathbf{x}} \max_{i=1, \dots, m} (\mathbf{a}_i^T \mathbf{x} + b_i)$$

等价于如下线性规划问题：

$$\begin{aligned} \min \quad & t \\ \text{s.t.} \quad & \mathbf{a}_i^T \mathbf{x} + b_i \leq t, \quad i = 1, \dots, m \end{aligned}$$

例 3

马尔科夫决策过程

在马尔科夫决策过程中, 考虑终止时间 $T = \infty$ 的情形。假设奖励有界, 为求出最优动作以及最优期望奖励, 将 *Bellman* 方程转化为如下线性规划问题:

$$\begin{aligned} \max_{V \in \mathbb{R}^{|S|}} \quad & \sum_i V(i) \\ \text{s.t.} \quad & V(i) \geq \sum_j P_a(i, j)(r(i, a) + \gamma V(j)), \forall i \in S, \forall a \in A, \end{aligned}$$

其中 $V(i)$ 是向量 V 的第 i 个分量, 表示从状态 i 出发得到的累积奖励, $P_a(i, j)$ 是转移概率, $r(i, a)$ 是单步奖励, γ 为折现因子。

例 4

多面体的 *Chebyshev* 中心

多面体 $\mathcal{P} = \{\mathbf{x} | \mathbf{a}_i^T \mathbf{x} \leq b_i, \quad i = 1, \dots, m\}$ 的 *Chebyshev* 中心是最大的内切球球心

$$\mathcal{B} = \{\mathbf{x}_c + \mathbf{u} | \|\mathbf{u}\|_2 \leq r\}$$

- 对于所有的 $\mathbf{x} \in \mathcal{B}$, 有 $\mathbf{a}_i^T \mathbf{x} \leq b_i$ 。这等价于

$$\sup\{\mathbf{a}_i^T(\mathbf{x}_c + \mathbf{u}) | \|\mathbf{u}\|_2 \leq r\} = \mathbf{a}_i^T \mathbf{x}_c + r\|\mathbf{a}_i\|_2 \leq b_i$$

- 因此 \mathbf{x}_c, r 可以通过解决一个 *LP* 问题被确定下来

$$\max \quad r$$

$$s.t. \quad \mathbf{a}_i^T \mathbf{x}_c + r\|\mathbf{a}_i\|_2 \leq b_i, \quad i = 1, \dots, m$$

例 5

压缩感知中的基追踪问题

基追踪问题是压缩感知中的一个基本问题, 可以写为

$$\begin{aligned} \min \quad & \|x\|_1, \\ \text{s.t.} \quad & Ax = b. \end{aligned}$$

对每个 $|x_i|$ 引入一个新的变量 z_i , 可以将问题 (11) 转化为

$$\begin{aligned} \min \quad & \sum_{i=1}^n z_i \\ \text{s.t.} \quad & Ax = b, \\ & -z_i \leq x_i \leq z_i, \quad i = 1, 2, \dots, n, \end{aligned}$$

这是一个线性规划问题.

例 6

分式线性问题

$$\begin{aligned} \min \quad & f_0(\mathbf{x}) \\ \text{s.t.} \quad & \mathbf{G}\mathbf{x} \leq \mathbf{h} \\ & \mathbf{A}\mathbf{x} = \mathbf{b} \end{aligned}$$

其中

$$f_0(\mathbf{x}) = \frac{\mathbf{c}^T \mathbf{x} + d}{\mathbf{e}^T \mathbf{x} + f}, \quad \text{dom } f_0 = \{\mathbf{x} | \mathbf{e}^T \mathbf{x} + f \geq 0\}$$

可以转换为等价的线性规划

$$\begin{aligned} \min \quad & \mathbf{c}^T \mathbf{y} + dz \\ \text{s.t.} \quad & \mathbf{G}\mathbf{y} - \mathbf{h}z \leq \mathbf{0} \\ & \mathbf{A}\mathbf{y} - \mathbf{b}z = \mathbf{0} \\ & \mathbf{e}^T \mathbf{y} + fz = 1 \\ & z \geq 0 \end{aligned}$$

31.2.2 二次规划 (QP)

$$\begin{aligned} \min \quad & (1/2)\mathbf{x}^T \mathbf{P} \mathbf{x} + \mathbf{q}^T \mathbf{x} + r \\ \text{s.t.} \quad & \mathbf{G} \mathbf{x} \leq \mathbf{h} \\ & \mathbf{A} \mathbf{x} = \mathbf{b} \end{aligned}$$

- $\mathbf{P} \in S_+^n$, 因此, 目标函数是凸二次型。
- 在多面体上极小化一个凸二次函数, 显然是凸优化问题。

例 7

最小二乘问题是经典的二次规划问题：

$$\min \quad \|Ax - b\|_2^2$$

- 解析解 $x = A^\dagger b$ ，其中， A^\dagger 是 A 的伪逆。
- 可以增加线性约束， $l \leq x \leq u$

例 8

随机线性规划问题

$$\begin{aligned} \min \quad & \bar{\mathbf{c}}^T \mathbf{x} + \gamma \mathbf{x}^T \Sigma \mathbf{x} = \mathbf{E}(\mathbf{c}^T \mathbf{x}) + \gamma \mathbf{var}(\mathbf{c}^T \mathbf{x}) \\ \text{s.t.} \quad & \mathbf{G}\mathbf{x} \leq \mathbf{h} \\ & \mathbf{A}\mathbf{x} = \mathbf{b} \end{aligned}$$

- \mathbf{c} 是随机向量，均值为 $\bar{\mathbf{c}}$ ，协方差 Σ
- 因此， $\mathbf{c}^T \mathbf{x}$ 是随机变量，均值 $\bar{\mathbf{c}}^T \mathbf{x}$ ，方差 $\mathbf{x}^T \Sigma \mathbf{x}$
- $\gamma > 0$ 为风险厌恶参数；权衡期望损失和方差 (风险)

31.2.3 二次约束二次规划 (QCQP)

$$\begin{aligned} \min \quad & (1/2)\mathbf{x}^T \mathbf{P}_0 \mathbf{x} + \mathbf{q}_0^T \mathbf{x} + r_0 \\ \text{s.t.} \quad & (1/2)\mathbf{x}^T \mathbf{P}_i \mathbf{x} + \mathbf{q}_i^T \mathbf{x} + r_i \leq 0, \quad i = 1, \dots, m \\ & \mathbf{A}\mathbf{x} = \mathbf{b} \end{aligned}$$

- $\mathbf{P}_i \in S_+^n$, $i = 0, \dots, m$, 目标和限制函数都是凸二次型
- 如果 $\mathbf{P}_i \in S_{++}^n$, 可行域是 m 个椭球和一个仿射集合的交集

31.2.4 二阶锥规划 (SOCP)

$$\begin{aligned}
\min \quad & \mathbf{f}^T \mathbf{x} \\
\text{s.t.} \quad & \|\mathbf{A}_i \mathbf{x} + \mathbf{b}_i\|_2 \leq \mathbf{c}_i^T \mathbf{x} + d_i, \quad i = 1, \dots, m \\
& \mathbf{F} \mathbf{x} = \mathbf{g}
\end{aligned}$$

其中 $\mathbf{A}_i \in \mathbb{R}^{n_i \times n}$ 以及 $\mathbf{F} \in \mathbb{R}^{p \times n}$ 。

- 不等式约束称为二阶锥 (SOC) 约束:

$(\mathbf{A}_i \mathbf{x}_i + \mathbf{b}_i, \mathbf{c}_i^T \mathbf{x}_i + d_i) \in R^{n_i+1}$ 的二阶锥中

- $\mathbf{c}_i = 0, i = 1, \dots, m$ 时, SOCP 等同于 QCQP。
- $\mathbf{A}_i = 0, i = 1, \dots, m$ 时, SOCP 退化为 LP。

例 9

鲁棒线性规划

优化问题中的参数经常是不确定的，例如，在线性规划中

$$\begin{aligned} \min \quad & \mathbf{c}^T \mathbf{x} \\ \text{s.t.} \quad & \mathbf{a}_i^T \mathbf{x} \leq b_i, \quad i = 1, \dots, m \end{aligned}$$

其中的参数 \mathbf{c} , \mathbf{a}_i , b_i 含有一些不确定性或变化。

两种通用方式处理不确定性 (简化起见, 这里只考虑 \mathbf{a}_i)

例 10

- 一种为确定性方法: 必须满足约束所有的 $\mathbf{a}_i \in \mathcal{E}_i$, 即

$$\begin{aligned} \min \quad & \mathbf{c}^T \mathbf{x} \\ \text{s.t.} \quad & \mathbf{a}_i^T \mathbf{x} \leq b_i, \quad \forall \mathbf{a}_i \in \mathcal{E}_i, \quad i = 1, \dots, m \end{aligned}$$

31.2.5 SOCP 确定性方法

- 给定椭球 \mathcal{E}_i :

$$\mathbf{a}_i \in \mathcal{E}_i = \{\bar{\mathbf{a}}_i + \mathbf{P}_i \mathbf{u} \mid \|\mathbf{u}\|_2 \leq 1\}$$

其中 $\bar{\mathbf{a}}_i \in \mathbb{R}^n$ 是椭球中心，半轴由 $\mathbf{P}_i \in \mathbb{R}^{n \times n}$ 的奇异值/奇异向量决定。

SOCP 确定性方法

- 由此得到鲁棒线性规划

$$\begin{aligned} \min \quad & \mathbf{c}^T \mathbf{x} \\ \text{s.t.} \quad & \mathbf{a}_i^T \mathbf{x} \leq b_i, \quad \forall \mathbf{a}_i \in \mathcal{E}_i, \quad i = 1, \dots, m \end{aligned}$$

等价于 SOCP

$$\begin{aligned} \min \quad & \mathbf{c}^T \mathbf{x} \\ \text{s.t.} \quad & \bar{\mathbf{a}}_i^T \mathbf{x} + \|\mathbf{P}_i^T \mathbf{x}\|_2 \leq b_i, \quad i = 1, \dots, m \end{aligned}$$

由 $\sup_{\|u\|_2} (\bar{\mathbf{a}}_i + \mathbf{P}_i u)^T \mathbf{x} = \bar{\mathbf{a}}_i^T \mathbf{x} + \|\mathbf{P}_i^T \mathbf{x}\|_2$ 得到。

例 11

- 另一种为随机性方法： \mathbf{a}_i 是随机变量；以概率 η 满足约束

$$\begin{aligned} \min \quad & \mathbf{c}^T \mathbf{x} \\ \text{s.t.} \quad & \mathbf{prob}(\mathbf{a}_i^T \mathbf{x} \leq b_i) \geq \eta, \quad i = 1, \dots, m \end{aligned}$$

31.2.6 SOCP 随机性方法

- 假设 \mathbf{a}_i 是服从高斯分布，均值为 $\bar{\mathbf{a}}_i$ ，协方差阵 Σ_i ，即 $\mathbf{a}_i \sim \mathcal{N}(\bar{\mathbf{a}}_i, \Sigma_i)$
- $\mathbf{a}_i^T \mathbf{x}$ 服从高斯分布，均值为 $\bar{\mathbf{a}}_i^T \mathbf{x}$ ，方差为 $\mathbf{x}^T \Sigma_i \mathbf{x}$ ；因此

$$\mathbf{prob}(\mathbf{a}_i^T \mathbf{x} \leq b_i) = \phi \left(\frac{b_i - \bar{\mathbf{a}}_i^T \mathbf{x}}{\|\Sigma_i^{1/2} \mathbf{x}\|_2} \right)$$

其中 $\phi(u) = \frac{1}{\sqrt{2\pi}} \int_{-\infty}^u e^{-t^2/2} dt$ 。

SOCP 随机性方法

• 鲁棒线性规划

$$\begin{aligned} \min \quad & \mathbf{c}^T \mathbf{x} \\ \text{s.t.} \quad & \mathbf{prob}(\mathbf{a}_i^T \mathbf{x} \leq b_i) \geq \eta, \quad i = 1, \dots, m, \end{aligned}$$

其中 $\eta \geq 1/2$, 等价于 SOCP

$$\begin{aligned} \min \quad & \mathbf{c}^T \mathbf{x} \\ \text{s.t.} \quad & \bar{\mathbf{a}}_i^T \mathbf{x} + \phi^{-1}(\eta) \|\Sigma_i^{1/2} \mathbf{x}\|_2 \leq b_i, \quad i = 1, \dots, m, \end{aligned}$$

31.2.7 半定规划 (SDP)

半定规划 (semidefinite programming, SDP) 是线性规划在矩阵空间中的一种推广, 它与线性规划不同的地方是其自变量取值于半正定矩阵空间。并具有如下一般形式

$$\begin{aligned} \min \quad & \mathbf{c}^T \mathbf{x} \\ \text{s.t.} \quad & x_1 \mathbf{F}_1 + \cdots + x_n \mathbf{F}_n + \mathbf{G} \preceq 0 \\ & \mathbf{A} \mathbf{x} = \mathbf{b} \end{aligned}$$

其中 $\mathbf{G}, \mathbf{F}_1, \cdots, \mathbf{F}_n$ 都是对称矩阵。如果这些矩阵为对角阵, 那么上式中的线性矩阵不等式 (LMI) 等价于 n 个线性不等式, 此时, SDP 便退化为线性规划。

仿照线性规划的分析，SDP 同样具有标准形式。标准形式的 SDP 具有对变量 $X \in S^m$ 的线性等式约束和（矩阵）非负定约束：

$$\begin{aligned} \min \quad & \text{Tr}(\mathbf{C}\mathbf{X}) \\ \text{s.t.} \quad & \text{Tr}(\mathbf{A}_i\mathbf{X}) = b_i, i = 1, \dots, p \\ & \mathbf{X} \succeq 0 \end{aligned}$$

其中 $\mathbf{C}, \mathbf{A}_1, \dots, \mathbf{A}_p \in S^m$ ， $\text{Tr}(\cdot)$ 是迹函数。

如同不等式形式的 LP，不等式形式的 SDP 不含有等式的约束，但是具有一个 LMI：

$$\begin{aligned} \min \quad & \mathbf{c}^T \mathbf{x} \\ \text{s.t.} \quad & x_1 \mathbf{A}_1 + \cdots + x_n \mathbf{A}_n \preceq \mathbf{B} \end{aligned}$$

其优化变量为 $\mathbf{x} \in \mathbb{R}^n$ ，参数为 \mathbf{B} ， $\mathbf{A}_1, \dots, \mathbf{A}_n \in S^k$ ， $\mathbf{c} \in \mathbb{R}^n$ 。

例 12

最大割问题的半定规划松弛 令 $G = \langle V, E \rangle$ 是一个无向图, 其中 V 是含有 n 个顶点的顶点集, E 表示边的集合。假定对于边 $(i, j) \in E$ 的权重为 w_{ij} 。最大割问题是找到节点集合 V 的一个子集 U , 使得 U 与它的补集 \bar{U} 之间相连边的权重之和最大化。若令 $x_i = 1, i \in U$ 和 $x_i = -1, i \in \bar{U}$, 则可得如下整数规划

$$\begin{aligned} \max \quad & \frac{1}{2} \sum_{i < j} (1 - x_i x_j) w_{ij} \\ \text{s.t.} \quad & x_i \in \{-1, 1\}, i = 1, 2, \dots, n. \end{aligned} \tag{1}$$

显然, 只有 x_i 与 x_j 不相等时, 即分别在集合 U 和 \bar{U} 中, 目标函数中 w_{ij} 的系数非零。该问题很难在多项式时间内找到它的最优解。接下来探讨如何将其松弛成一个半定规划问题。

(续) 令 \mathbf{W} 表示无向图的邻接矩阵, \mathbf{D} 表示该图的度矩阵, 并定义 $\mathbf{A} = -\frac{1}{4}(\mathbf{D} - \mathbf{W})$ 为图的拉普拉斯矩阵的 $-\frac{1}{4}$ 倍, 则问题(1)可以等价地写为

$$\begin{aligned} \min \quad & \mathbf{x}^T \mathbf{A} \mathbf{x} \\ \text{s.t.} \quad & x_i^2 = 1, \quad i = 1, 2, \dots, n. \end{aligned} \tag{2}$$

(续) 现在令 $\mathbf{X} = \mathbf{x}\mathbf{x}^T$, 注意到约束条件 $x_i^2 = 1$ 。利用矩阵形式, 我们可将最大割问题化为

$$\begin{aligned} \min \quad & \langle \mathbf{A}, \mathbf{X} \rangle \\ \text{s.t.} \quad & X_{ii} = 1, \quad i = 1, 2, \dots, n, \\ & \mathbf{X} \succeq 0, \\ & \text{rank}(\mathbf{X}) = 1. \end{aligned} \tag{3}$$

(续) 容易验证问题(2)与(3)是等价的。现在将问题(3)的约束 $\text{rank}(\mathbf{X}) = 1$ 去掉, 那么便得到最大割的半定规划松弛形式

$$\begin{aligned} \min \quad & \langle \mathbf{A}, \mathbf{X} \rangle \\ \text{s.t.} \quad & X_{ii} = 1, \quad i = 1, 2, \dots, n, \\ & \mathbf{X} \succeq 0. \end{aligned} \tag{4}$$

需要声明的是问题(4)与原问题并不等价, 但确实能得到一个较好的近似解。

本讲小结

凸优化

- 凸优化的概念
- 凸优化的一些等价转换
- 凸优化的全局最优性

典型的凸优化问题

- 线性规划
- 二次规划
- 二次约束二次规划
- ...

我们已经了解凸优化相关的许多概念。在实际问题中，也经常遇到凸优化问题。那么怎么去求解凸优化问题呢？这就是接下来要介绍的内容。